

Keşifsel Veri Analizi (EDA)

Diyabet Tahmini İçin Makine Öğrenmesi Tabanlı Sınıflandırma Sistemi

Diyabet, dünya genelinde milyonlarca insanı etkileyen kronik metabolik hastalıklardan biridir. Erken teşhis ve uygun tedavi uygulanmadığında kalp hastalıkları, böbrek yetmezliği, görme kaybı ve sinir sistemi hasarları gibi ciddi komplikasyonlara yol açabilmektedir.

Bu çalışmanın amacı, bireylerin çeşitli sağlık göstergeleri kullanılarak diyabet hastası olup olmadıklarının tahmin edilmesidir. Model geliştirme sürecinden önce veri setinin yapısını anlamak, değişkenler arasındaki ilişkileri incelemek ve veri kalitesini değerlendirmek amacıyla **Keşifsel Veri Analizi (EDA)** gerçekleştirilmiştir.

Veri Setinin Tanıtılması

Bu çalışmada Kaggle ve UCI Machine Learning Repository kaynaklarında yaygın olarak kullanılan Pima Indians Diabetes Dataset kullanılmıştır. Veri seti yalnızca kadın bireylerden oluşmakta olup toplam 768 gözlem içermektedir. Toplam Değişken Sayısı ise 9'dur.

df										
	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome	
0	6	148	72	35	0	33.6	0.627	50	1	
1	1	85	66	29	0	26.6	0.351	31	0	
2	8	183	64	0	0	23.3	0.672	32	1	
3	1	89	66	23	94	28.1	0.167	21	0	
4	0	137	40	35	168	43.1	2.288	33	1	
...	...	...	...	...	...	...	...	...	...	
763	10	101	76	48	180	32.9	0.171	63	0	
764	2	122	70	27	0	36.8	0.340	27	0	
765	5	121	72	23	112	26.2	0.245	30	0	
766	1	126	60	0	0	30.1	0.349	47	1	
767	1	93	70	31	0	30.4	0.315	23	0	

768 rows × 9 columns

Veri Setinin Genel Özellikleri

Özellik	Değer
Veri Seti Adı	Pima Indians Diabetes Dataset
Toplam Gözlem Sayısı	768
Toplam Değişken Sayısı	9
Bağımsız Değişken Sayısı	8
Hedef Değişken	Outcome
Problem Türü	İkili (Binary) Sınıflandırma
Veri Türü	Sayısal (Numerik)
Eksik Değer Durumu	Doğrudan eksik değer bulunmamaktadır

Hedef değişken olan **Outcome**, bireyin diyabet durumunu ifade etmektedir.

Veri Yapısının İncelenmesi

```
df.dtypes
```

```
Pregnancies      int64
Glucose           int64
BloodPressure     int64
SkinThickness     int64
Insulin           int64
BMI              float64
DiabetesPedigreeFunction float64
Age              int64
Outcome           int64
dtype: object
```

Yapılan analiz sonucunda:

- Veri setinde toplam 768 satır bulunmaktadır.
- Tüm değişkenler sayısal yapıdadır.
- Kategorik değişken bulunmamaktadır.
- Veri seti makine öğrenmesi algoritmalarına uygun yapıdadır.

Eksik Değer Isı Haritası (Missing Value Heatmap)


İlk aşamada aşağıdaki komutlar kullanılarak eksik veri analizi yapılmıştır:

```
df.isnull().sum()
```

Sonuçlar incelendiğinde veri setinde doğrudan eksik (Null) değer bulunmadığı görülmüştür.

```
sns.heatmap(df.isnull(),cbar=False)
```

<Axes: >



Veri setindeki eksik değerlerin dağılımını incelemek amacıyla eksik değer ısı haritası oluşturulmuştur. Isı haritasında her satır bir gözlemi, her sütun ise bir değişkeni temsil etmektedir. Eksik değer bulunan hücreler farklı bir renkle gösterilmektedir.

Yapılan analiz sonucunda veri setinde herhangi bir NULL (NaN) değerin bulunmadığı görülmüştür. Bu nedenle ısı haritasında tüm hücreler aynı renkte görünmektedir. Bu durum, veri setinin teknik olarak eksik veri içermediğini göstermektedir.

Değişken Açıklamaları

- **Pregnancies:** Bireyin sahip olduğu toplam gebelik sayısını ifade etmektedir.
- **Glucose:** Kandaki glikoz (şeker) seviyesini göstermektedir ve diyabet teşhisinde en önemli göstergelerden biridir.
- **BloodPressure:** Diyastolik kan basıncı (küçük tansiyon) değerini ifade etmektedir.
- **SkinThickness:** Triseps bölgesinden ölçülen deri kıvrım kalınlığıdır.
- **Insulin:** Kandaki insülin seviyesini göstermektedir.
- **BMI (Body Mass Index):** Bireyin boy ve kilosuna göre hesaplanan vücut kitle indeksidir.
- **DiabetesPedigreeFunction:** Bireyin aile geçmişine bağlı diyabet riskini temsil eden bir ölçüttür.
- **Age:** Bireyin yaş bilgisini ifade etmektedir.
- **Outcome:** Bireyin diyabet hastası olup olmadığını göstermektedir.

Hedef Değişken (Outcome)

Bu çalışmada tahmin edilmek istenen değişken **Outcome** değişkenidir.

- **Outcome = 0:** Birey diyabet hastası değildir.
- **Outcome = 1:** Birey diyabet hastasıdır.

Dolayısıyla proje, sağlık verileri kullanılarak bireyin diyabet hastası olup olmadığını tahmin etmeyi amaçlayan bir **ikili sınıflandırma (Binary Classification)** problemidir

Outcome dağılımı grafiği: veri setindeki diyabetli ve diyabet olmayan bireylerin dağılımını gösteren grafik.


Yorum

Veri setinde orta düzeyde sınıf dengesizliği bulunmaktadır.

Bu nedenle model değerlendirmesinde yalnızca Accuracy metriği kullanılmamış;

- Precision
- Recall
- F1 Score
- ROC-AUC

değerleri de incelenmiştir.



İstatistiksel Özet Analizi

Temel İstatistikler

```
df.describe()
```

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
count	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000
mean	3.845052	120.894531	69.105469	20.536458	79.799479	31.992578	0.471876	33.240885	0.348958
std	3.369578	31.972618	19.355807	15.952218	115.244002	7.884160	0.331329	11.760232	0.476951
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.078000	21.000000	0.000000
25%	1.000000	99.000000	62.000000	0.000000	0.000000	27.300000	0.243750	24.000000	0.000000
50%	3.000000	117.000000	72.000000	23.000000	30.500000	32.000000	0.372500	29.000000	0.000000
75%	6.000000	140.250000	80.000000	32.000000	127.250000	36.600000	0.626250	41.000000	1.000000
max	17.000000	199.000000	122.000000	99.000000	846.000000	67.100000	2.420000	81.000000	1.000000

Glucose

Ortalama glikoz değeri 120.89'dur.

Maksimum değer 199 olup yüksek varyasyon gözlenmektedir.

BMI

Ortalama BMI değeri 31.99'dur.

Bu değer obezite sınırına oldukça yakındır.

Age

Ortalama yaş 33.24'tür.

Veri seti ağırlıklı olarak genç ve orta yaşlı bireylerden oluşmaktadır.


Insulin

Standart sapma değeri oldukça yüksektir.

Bu durum veri setinde aykırı gözlemler bulunduğunu göstermektedir.

Korelasyon Analizi

Korelasyon Matrisi



Korelasyon Sayısal Değerleri

Outcome değişkeni ile aralarındaki ilişkiyi incelersek :

En güçlü ilişki Glucose değişkeninde görülmektedir.

Bu sonuç diyabetin temel göstergelerinden biri olan kan şekeri seviyesi ile uyumludur.


BMI ve Age değişkenleri de diyabet oluşumunda önemli faktörler olarak öne çıkmaktadır.

```
df.corr()
```

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
Pregnancies	1.000000	0.129459	0.141282	-0.081672	-0.073535	0.017683	-0.033523	0.544341	0.221898
Glucose	0.129459	1.000000	0.152590	0.057328	0.331357	0.221071	0.137337	0.263514	0.466581
BloodPressure	0.141282	0.152590	1.000000	0.207371	0.088933	0.281805	0.041265	0.239528	0.065068
SkinThickness	-0.081672	0.057328	0.207371	1.000000	0.436783	0.392573	0.183928	-0.113970	0.074752
Insulin	-0.073535	0.331357	0.088933	0.436783	1.000000	0.197859	0.185071	-0.042163	0.130548
BMI	0.017683	0.221071	0.281805	0.392573	0.197859	1.000000	0.140647	0.036242	0.292695
DiabetesPedigreeFunction	-0.033523	0.137337	0.041265	0.183928	0.185071	0.140647	1.000000	0.033561	0.173844
Age	0.544341	0.263514	0.239528	-0.113970	-0.042163	0.036242	0.033561	1.000000	0.238356
Outcome	0.221898	0.466581	0.065068	0.074752	0.130548	0.292695	0.173844	0.238356	1.000000

Feature Distribution Grafikleri

Bu bölümde veri setinde yer alan tüm değişkenlerin dağılımlarını incelemek amacıyla histogram grafikleri oluşturulmuştur. Histogramlar, değişkenlerin hangi değer aralıklarında yoğunlaştığını, dağılım şekillerini ve olası aykırı değerleri gözlemlemeye yardımcı olmaktadır.



Pregnancies (Gebelik Sayısı)

Gebelik sayısı değişkeni incelendiğinde bireylerin büyük çoğunluğunun düşük sayıda gebelik geçirdiği görülmektedir. Dağılım sağa çarpık bir yapı göstermektedir ve yüksek gebelik sayılarına sahip bireylerin sayısı oldukça azdır.

Glucose (Kan Şekeri)

Glucose değişkeni geniş bir dağılıma sahiptir. Özellikle yüksek glikoz değerlerine sahip bireylerin bulunduğu görülmektedir. Diyabet ile en güçlü ilişkiye sahip değişkenlerden biri olması nedeniyle bu dağılım model performansı açısından önemli bir göstergedir.

BloodPressure (Kan Basıncı)

Kan basıncı değerleri genel olarak normal fizyolojik aralıklar etrafında yoğunlaşmıştır. Ancak bazı sıfır değerlerin bulunması ölçüm eksikliğine işaret etmektedir.

SkinThickness (Deri Kalınlığı)

SkinThickness değişkeninde sıfır değerlerin oldukça fazla olduğu görülmektedir. Bunun yanı sıra dağılım belirli bir aralıkta yoğunlaşmakta ve bazı yüksek değerler aykırı gözlem niteliği taşımaktadır.

İnsulin (İnsülin Seviyesi)

İnsülin değişkeni veri setindeki en yüksek değişkenliğe sahip özelliklerden biridir. Dağılım oldukça sağa çarpıktır ve yüksek insülin değerlerine sahip aykırı gözlemler bulunmaktadır. Ayrıca çok sayıda sıfır değeri içermektedir. İnsulin değişkeni yüksek varyansa sahiptir.

BMI (Vücut Kitle İndeksi)

BMI değerleri ağırlıklı olarak 25-40 aralığında yoğunlaşmıştır. Bu durum veri setindeki bireylerin önemli bir kısmının fazla kilolu veya obez kategorisinde yer aldığını göstermektedir.

DiabetesPedigreeFunction (Genetik Diyabet Riski)

Bu değişken düşük değerlerde yoğunlaşmaktadır. Yüksek değerlere sahip birey sayısı oldukça sınırlıdır.

Age (Yaş)


Yaş dağılımı incelendiğinde veri setinin büyük kısmının genç ve orta yaşlı bireylerden oluştuğu görülmektedir. İleri yaş gruplarında gözlem sayısı giderek azalmaktadır.

Değerlendirme

Histogram analizleri sonucunda bazı değişkenlerin normal dağılıma sahip olmadığı, özellikle **Glucose**, **Insulin**, **BMI** ve **DiabetesPedigreeFunction** değişkenlerinde çarpıklık bulunduğu gözlemlenmiştir. Ayrıca bazı değişkenlerde aykırı değerler ve tıbbi açıdan gerçekçi olmayan sıfır değerler tespit edilmiştir. Bu nedenle modelleme aşamasında veri ölçeklendirme (StandardScaler ve MinMaxScaler) işlemleri uygulanmış ve eksik veri problemleri giderilmiştir.

Kutu Grafiği Analizi

Veri setinde yer alan değişkenlerin dağılımlarını daha ayrıntılı incelemek ve aykırı gözlemleri belirlemek amacıyla kutu grafikleri (boxplot) oluşturulmuştur. Kutu grafikleri, medyan değeri, çeyrekler arası açıklık (IQR), minimum ve maksimum değerler ile aykırı gözlemleri görsel olarak incelemeye olanak sağlamaktadır.



Bulgular

Kutu grafikleri incelendiğinde veri setindeki bazı değişkenlerde önemli düzeyde aykırı değerlerin bulunduğu görülmüştür. Özellikle:

- **Glucose (Kan Şekeri)**
- **Insulin (İnsülin Seviyesi)**
- **BMI (Vücut Kitle İndeksi)**

değişkenlerinde çok sayıda aykırı gözlem tespit edilmiştir.

Glucose Değişkeni

Kan şekeri değerlerinde üst sınırın oldukça üzerinde yer alan gözlemler bulunmaktadır. Bu durum bazı bireylerde ciddi hiperglisemi (yüksek kan şekeri) vakalarının bulunduğunu göstermektedir. Diyabet tanısında glikoz seviyesinin kritik öneme sahip olması nedeniyle bu gözlemler veri setinden çıkarılmamıştır.

Insulin Değişkeni

İnsülin değişkeni veri setindeki en yüksek varyansa sahip değişkenlerden biridir. Kutu grafiğinde çok sayıda yüksek değerli aykırı gözlem görülmektedir. Bunun nedeni bireylerin insülin seviyeleri arasındaki biyolojik farklılıklar ve bazı bireylerde görülen ciddi metabolik bozukluklar olabilir.

BMI Değişkeni


BMI değişkeninde de üst sınırın üzerinde yer alan değerler gözlenmiştir. Bu değerler ileri düzey obez bireyleri temsil edebileceğinden veri setinden çıkarılmamıştır. Obezite, diyabet gelişiminde önemli risk faktörlerinden biri olduğundan bu gözlemler model için değerli bilgi içermektedir.

Genel Değerlendirme

Makine öğrenmesi projelerinde aykırı değerler çoğu zaman veri hatası olarak değerlendirilse de sağlık verilerinde bu durum her zaman geçerli değildir. Bu çalışmada tespit edilen aykırı değerlerin büyük çoğunluğunun gerçek klinik vakaları temsil ettiği düşünülmüştür. Bu nedenle herhangi bir aykırı değer silme işlemi uygulanmamış ve tüm gözlemler model eğitim sürecine dahil edilmiştir. Aykırı değerlerin model performansı üzerindeki olası etkilerini azaltmak ve modellerin en uygun parametrelerle çalışmasını sağlamak amacıyla GridSearchCV yöntemi kullanılarak hiperparametre optimizasyonu gerçekleştirilmiştir. Böylece modellerin veri setine daha iyi uyum sağlaması ve genelleme performanslarının artırılması hedeflenmiştir.

Diyabetli ve Sağlıklı Bireylerin Karşılaştırılması

Veri setindeki değişkenlerin diyabet durumu üzerindeki etkisini incelemek amacıyla her özellik için Outcome değişkenine göre kutu grafikleri oluşturulmuştur. Bu analiz sayesinde diyabetli ve diyabetli olmayan bireyler arasındaki farklılıklar görsel olarak değerlendirilmiştir.



Glucose (Kan Şekeri)

Grafikler incelendiğinde diyabetli bireylerin glikoz seviyelerinin diyabetli olmayan bireylere göre belirgin şekilde daha yüksek olduğu görülmektedir. Ayrıca diyabetli bireylerde glikoz dağılımının daha geniş olduğu dikkat çekmektedir.

Bu sonuç, korelasyon analizinde elde edilen **0.467 korelasyon katsayısı** ile uyumludur ve Glucose değişkeninin diyabet tahminindeki en güçlü değişken olduğunu göstermektedir.

BMI (Vücut Kitle İndeksi)

Diyabet tanısı alan bireylerin BMI değerlerinin genel olarak daha yüksek olduğu görülmektedir. Bu durum fazla kilo ve obezitenin diyabet gelişiminde önemli bir risk faktörü olduğunu desteklemektedir. Korelasyon analizinde BMI değişkeninin Outcome ile **0.293** korelasyon göstermesi de bu bulguyu doğrulamaktadır.

Age (Yaş)

Yaş değişkeni incelendiğinde diyabetli bireylerin yaş dağılımının sağlıklı bireylere göre daha yüksek olduğu görülmektedir. İleri yaş gruplarında diyabet görülme sıklığının arttığı gözlemlenmiştir. Bu sonuç, yaş ile diyabet arasındaki pozitif ilişkinin görsel bir kanıtı niteliğindedir.

Pregnancies (Gebelik Sayısı)

Diyabetli bireylerde ortalama gebelik sayısının daha yüksek olduğu görülmektedir. Bunun temel nedeni yaştan artmasıyla birlikte gebelik sayısının da artabilmesi ve ileri yaşlarda diyabet riskinin yükselmesidir.

Insulin ve SkinThickness

Bu değişkenlerde iki grup arasında belirli farklılıklar gözlenirse de Glucose ve BMI kadar güçlü bir ayrışma görülmemektedir. Bunun temel nedeni değişkenlerdeki yüksek varyans ve çok sayıda eksik/sıfır değer bulunmasıdır.

Genel Değerlendirme

Diyabetli ve sağlıklı bireylerin karşılaştırılması sonucunda özellikle Glucose, BMI ve Age değişkenlerinin iki grup arasında belirgin farklılık oluşturduğu görülmüştür. Bu değişkenler hem korelasyon analizinde hem de görsel analizlerde en güçlü ayırt edici özellikler olarak öne çıkmıştır. Elde edilen sonuçlar literatürde yer alan çalışmalarla uyumludur ve geliştirilen makine öğrenmesi modellerinin bu değişkenlerden yüksek

düzeyde faydalanabileceğini göstermektedir. Bu nedenle model geliştirme aşamasında söz konusu değişkenlerin tahmin performansına önemli katkı sağlaması beklenmektedir.

Sıfır Değer Analizi

```
(df == 0).sum()
```

Pregnancies	111
Glucose	5
BloodPressure	35
SkinThickness	227
Insulin	374
BMI	11
DiabetesPedigreeFunction	0
Age	0
Outcome	500
dtype:	int64

Özellikle:

- Insulin (%48.7)
- SkinThickness (%29.5)

değişkenlerinde çok sayıda sıfır değer bulunmaktadır. Tıbbi açıdan değerlendirildiğinde bazı değişkenlerde bulunan sıfır değerlerin saçma ve mantıksız olduğu, gerçek ölçüm olmadığı anlaşılmaktadır. Bu değerler eksik veri olarak değerlendirilmiştir. Bu 0 değerler düzenlenmiştir.

Eksik Veri İşleme

Eksik verileri daha anlamlı şekilde kullanabilmek amacıyla aşağıdaki yöntem uygulanmıştır:

1. Sıfır değerler NaN yapılmıştır.
2. Medyan değer ile doldurulmuştur.
3. Eksik veri göstergeleri oluşturulmuştur.

Örneğin:

- Glucose_missing
- BloodPressure_missing
- SkinThickness_missing
- Insulin_missing
- BMI_missing

şeklinde 5 yeni değişken üretilmiştir.

```
print (df_flag.columns.tolist())
```

```
['Pregnancies', 'Glucose', 'BloodPressure', 'SkinThickness', 'Insulin', 'BMI', 'DiabetesPedigreeFunction', 'Age', 'Outcome', 'Glucose_missing', 'BloodPressure_missing', 'SkinThickness_missing', 'Insulin_missing', 'BMI_missing']
```

Bu işlem sonrasında veri setindeki özellik sayısı 8 iken 13 olmuştur. Bu yaklaşım eksik bilginin modele aktarılmasını sağlamıştır.

Öznitelik Mühendisliği (Feature Engineering)

Keşifsel Veri Analizi sürecinde veri setinde doğrudan eksik değer (NaN) bulunmadığı görülmesine rağmen bazı değişkenlerde tıbbi açıdan gerçekçi olmayan sıfır (0) değerlerin yer aldığı tespit edilmiştir. Özellikle Glucose, BloodPressure, SkinThickness, Insulin ve BMI değişkenlerinde bulunan sıfır değerlerin eksik veya ölçülmemiş verileri temsil ettiği değerlendirilmiştir.

Bu problemin çözülmesi amacıyla veri ön işleme aşamasında öznitelik mühendisliği uygulanmıştır. İlk olarak ilgili değişkenlerde bulunan sıfır değerler NaN olarak değerlendirilmiş, daha sonra veri kaybını önlemek amacıyla her değişkenin medyan değeri ile doldurulmuştur.

Ancak eksik bilgilerin tamamen kaybolmaması için her değişken adına ek bir gösterge (indicator) değişkeni oluşturulmuştur. Böylece model yalnızca doldurulan değeri değil, aynı zamanda o değer başlangıçta eksik olup olmadığını da öğrenebilmektedir.

Oluşturulan yeni değişkenler aşağıdaki gibidir:

- Glucose_missing
- BloodPressure_missing
- SkinThickness_missing
- Insulin_missing
- BMI_missing

Bu değişkenler ilgili sütunda sıfır değer bulunuyorsa 1, bulunmuyorsa 0 değerini almaktadır.

Örneğin;

- $\text{Insulin} = 0$ ise $\rightarrow \text{Insulin_missing} = 1$
- $\text{Insulin} \neq 0$ ise $\rightarrow \text{Insulin_missing} = 0$

Bu yaklaşım özellikle sağlık verilerinde yaygın olarak kullanılan bir eksik veri yönetim yöntemidir ve modelin eksik ölçüm bilgisinden de faydalanmasını sağlamaktadır.

Model eğitime başlamadan önce veri seti %70 eğitim ve %30 test olacak şekilde ayrılmıştır. Model performansını artırmak amacıyla ayrıca StandardScaler ve MinMaxScaler yöntemleri kullanılarak veri ölçeklendirme işlemleri de gerçekleştirilmiştir. Böylece değişkenlerin farklı büyüklüklerden kaynaklanan etkileri azaltılmış ve özellikle SVM ve Neural Network modellerinin daha verimli çalışması sağlanmıştır. Sonuç olarak uygulanan öznitelik mühendisliği çalışmaları sayesinde veri setinin bilgi içeriği artırılmış ve makine öğrenmesi modelleri için daha uygun bir yapı elde edilmiştir.

EDA Sonuçları ve Modelleme Sürecine Etkileri

Gerçekleştirilen keşifsel veri analizi sonucunda veri setinin yapısı ayrıntılı olarak incelenmiş ve model geliştirme aşamasında kullanılabilecek önemli bilgiler elde edilmiştir. İlk olarak veri setinde doğrudan eksik değer bulunmadığı görülmüş, ancak bazı değişkenlerde yer alan sıfır değerlerin gerçekte eksik verileri temsil ettiği tespit edilmiştir. Bu nedenle eksik veri yönetimi uygulanmış ve veri kalitesi artırılmıştır.

Outcome ile korelasyon katsayılarından edindiğimiz bilgiler sayesinde belli yorumlar çıkarabiliriz. Diyabet riskinin özellikle kan şekeri seviyesi, vücut kitle indeksi ve yaş ile yakından ilişkili olduğunu söyleyebiliriz.

Histogram ve kutu grafikleri incelendiğinde veri setinde önemli sayıda aykırı gözlem bulunduğu görülmüştür. Özellikle Glucose, Insulin ve BMI değişkenlerinde yüksek varyans ve aykırı değerler tespit edilmiştir. Ancak bu değerlerin gerçek klinik vakaları temsil etme ihtimali yüksek olduğundan veri setinden çıkarılmamıştır.

Sınıf dağılımı analizinde;

Diyabet olmayan birey sayısı: 500

Diyabetli birey sayısı: 268 olarak bulunmuştur.

Bu durum veri setinde tam olmasa da belirli düzeyde bir sınıf dengesizliği bulunduğunu göstermektedir. Bu nedenle model değerlendirmelerinde yalnızca Accuracy metriği kullanılmamış; F1 Score, ROC-AUC ve RMSE değerleri de dikkate alınmıştır.

EDA sürecinde elde edilen bulgular doğrultusunda dört farklı makine öğrenmesi modeli geliştirilmiştir:

1. Logistic Regression
2. Support Vector Machine (SVM)
3. Neural Network
4. XGBoost

Modeller üzerinde GridSearchCV ve RandomizedSearchCV yöntemleri kullanılarak hiperparametre optimizasyonu gerçekleştirilmiştir.

Optimizasyon sonrasında elde edilen doğruluk sonuçları aşağıdaki gibidir:

Model	Accuracy
SVM	0.801
Logistic Regression	0.797
Neural Network	0.745
XGBoost	0.740

Tablo incelendiğinde en yüksek doğruluk oranının %80.1 ile SVM modelinde elde edildiği görülmektedir. Logistic Regression modeli %79.7 doğruluk oranı ile SVM modeline oldukça yakın sonuç vermiştir.

F1-Score Karşılaştırması

Model	F1-Score
SVM	0.693
Logistic Regression	0.680
Neural Network	0.604

F1-Score metriği, precision ve recall değerlerinin harmonik ortalamasını ifade etmekte olup özellikle sınıf dengesizliğinin bulunduğu veri setlerinde önemli bir performans göstergesidir. Sonuçlar incelendiğinde en yüksek F1-Score değerinin 0.693 ile SVM modeline ait olduğu görülmektedir.

Modellerin ROC-AUC Karşılaştırması

Model	ROC-AUC
Logistic Regression	0.855
SVM	0.835
Neural Network	0.794

ROC-AUC metriği, modelin sınıfları birbirinden ayırabilme yeteneğini ölçmektedir. Değerin 1'e yaklaşması model performansının arttığını göstermektedir. Elde edilen sonuçlara göre en yüksek ROC-AUC değeri 0.855 ile Logistic Regression modelinde elde edilmiştir. SVM modeli 0.835 ROC-AUC değeri ile başarılı bir performans sergilemiş, Neural Network modeli ise 0.794 değeri ile diğer modellerin gerisinde kalmıştır.

Bu sonuçlar değerlendirildiğinde, doğruluk oranı açısından SVM modeli öne çıkarken, sınıfları ayırt etme başarısı bakımından Logistic Regression modeli en başarılı model olarak dikkat çekmektedir. Genel performans açısından değerlendirildiğinde SVM ve Logistic Regression modellerinin veri seti üzerinde en başarılı sonuçları ürettiği söylenebilir.

Dipnot:

Genel olarak EDA süreci veri setinin güçlü ve zayıf yönlerini ortaya çıkarmış, eksik veri yönetimi ve öznitelik mühendisliği çalışmalarına rehberlik etmiş ve model geliştirme sürecinde kullanılacak algoritmaların seçiminde önemli rol oynamıştır. Elde edilen bulgular doğrultusunda geliştirilen modeller diyabet tahmini probleminde başarılı sonuçlar üretmiş ve veri setinin makine öğrenmesi uygulamaları için uygun olduğu doğrulanmıştır.